

Entrega 4 - Diseño del análisis y estrategia de modelado

Enunciado de la cuarta entrega incremental del proyecto.

Contexto de la entrega

En las entregas anteriores definisteis la idea de producto, seleccionasteis el proyecto con el que vais a continuar, analizasteis la disponibilidad y viabilidad de los datos y diseñasteis el modelo de datos y la capa gold que servirá como entrada para las siguientes fases.

En esta cuarta entrega debéis avanzar desde la preparación de los datos hacia el diseño del análisis y del modelado. El objetivo no es todavía construir el modelo definitivo, sino concretar qué preguntas responderéis con los datos, qué utilidad aportará el análisis, qué modelos tiene sentido comparar y cómo demostraréis que los resultados son válidos y útiles.

Un proyecto de Data Science no consiste en escoger primero un algoritmo. Debe partir de un problema concreto, utilizar datos adecuados, comparar alternativas razonables y evaluar si el modelo generaliza y mejora una referencia simple.

Objetivo

El objetivo de esta entrega es definir la estrategia de análisis y modelado del proyecto. Debéis explicar qué problema queréis resolver, qué análisis realizaréis, qué modelos vais a plantear, cuáles serán sus datos de entrada y salida y qué proceso seguiréis para seleccionar y validar la solución más adecuada.

Estructura obligatoria del repositorio

```
docs/  
  -- entregas/  
    -- 01_ideas_producto.md  
    -- 02_datos_necesarios.md  
    -- 03_modelo_datos.md  
    -- 04_analisis_modelado.md
```

En esta entrega espero encontrar, como mínimo, los siguientes ficheros dentro de docs/entregas/:

- **01_ideas_producto.md:** debe contener el resultado de la entrega 1, con las ideas de producto planteadas inicialmente.
- **02_datos_necesarios.md:** debe contener el resultado de la entrega 2, con la idea seleccionada, los datos necesarios, las fuentes previstas, la privacidad y la viabilidad inicial.
- **03_modelo_datos.md:** debe contener el resultado de la entrega 3, con la estructura de datos, la capa gold, el diccionario inicial y las transformaciones previstas.
- **04_analisis_modelado.md:** debe contener el desarrollo completo de esta entrega 4.

La entrega debe ser incremental. No debéis borrar ni sustituir las entregas anteriores. Si el diseño del análisis obliga a modificar alguna decisión previa, explicad el cambio y actualizad la documentación manteniendo la trazabilidad.

Contenido del fichero 04_analisis_modelado.md

1. Problema que se busca resolver

Resumid el problema concreto que aborda el proyecto y conectadlo con la decisión, proceso o necesidad que queréis mejorar. No se trata de repetir toda la entrega 2, sino de precisar qué resultado esperáis obtener mediante el análisis o el modelo.

- Qué ocurre actualmente y por qué supone un problema.
- Quién utilizará el resultado y para qué decisión o acción.
- Qué resultado concreto debería producir el proyecto para considerarse útil.

2. Análisis de datos planteado y utilidad esperada

Explicad qué análisis realizaréis antes, durante y después del modelado y qué utilidad aporta cada uno. El análisis debe estar relacionado con el problema y no limitarse a una lista genérica de gráficos.

- Qué preguntas queréis responder con los datos.
- Qué análisis descriptivos, comparativos, temporales, geográficos, segmentaciones o relaciones entre variables vais a estudiar.
- Qué hipótesis o patrones queréis comprobar.
- Qué visualizaciones, indicadores o conclusiones podrían incorporarse al MVP.
- Cómo ayudará este análisis a comprender el problema, preparar el modelado o apoyar una decisión.

No todos los proyectos necesitan el mismo tipo de análisis. Un proyecto de predicción temporal deberá estudiar tendencia y estacionalidad; uno de clasificación deberá revisar el equilibrio de clases y la relación entre variables y objetivo; uno de recomendación deberá analizar usuarios, elementos e interacciones.

3. Tipo de modelos que se van a plantear

Indicad qué tipo de problema de modelado vais a abordar y qué familias de modelos tiene sentido probar. No se valorará proponer muchos algoritmos, sino seleccionar alternativas coherentes con el problema, los datos y el tiempo disponible.

- Tipo de tarea: regresión, clasificación, forecasting, clustering, recomendación, detección de anomalías, NLP, reglas o score, u otra opción justificada.
- Modelo de referencia o baseline sencillo contra el que compararéis las alternativas.
- Uno o varios modelos candidatos, explicando por qué pueden ser adecuados.
- Ventajas y limitaciones esperadas de cada alternativa: precisión, interpretabilidad, coste, complejidad o necesidad de datos.
- Si el proyecto no requiere un modelo predictivo, justificadlo y explicad qué lógica analítica, estadística o basada en reglas sustituirá al modelado.

Alternativa	Tipo	Por qué se plantea	Limitación principal
Baseline	Media, regla simple, modelo naïve, clase mayoritaria...	Proporciona una referencia mínima y permite saber si el modelo aporta mejora.	Puede ser poco preciso, pero debe ser difícil de superar de forma trivial.
Modelo candidato 1	Modelo interpretable o sencillo	Permite construir una primera solución reproducible y explicable.	Puede no capturar relaciones complejas.
Modelo candidato 2	Modelo más flexible o avanzado	Permite comprobar si una mayor complejidad mejora realmente el resultado.	Mayor riesgo de sobreajuste o menor interpretabilidad.

4. Datos de entrada del análisis y los modelos

Definid con claridad qué datos de la capa gold utilizaréis como entrada. La unidad de análisis y la disponibilidad temporal de las variables deben quedar perfectamente identificadas.

- Nombre del dataset, tabla o vista de la capa gold que se utilizará.
- Granularidad: qué representa exactamente cada fila.
- Clave o identificador principal y fecha de referencia, si aplica.
- Variables de entrada principales y transformaciones necesarias.
- Variables que no se utilizarán y motivo: falta de calidad, redundancia, privacidad o riesgo de fuga de información.
- Qué información estaría realmente disponible en el momento de generar la predicción o resultado.

Entrada	Descripción	Granularidad / tipo	Uso en el análisis o modelo
gold_xxx	Dataset final procedente de la entrega 3.	Una fila por...	Fuente principal de variables de entrada.
variable_1	Descripción funcional de la variable.	Numérica / categórica / fecha / texto	Feature directa o variable para análisis.
variable_derivada	Variable calculada a partir de datos históricos.	Numérica / indicador	Resume comportamiento previo o contexto.

5. Datos de salida y forma de consumo

Definid qué producirá el análisis o el modelo y cómo se integrará en el MVP. La salida debe ser concreta, interpretable y trazable hasta la entidad o periodo analizado.

- Variable objetivo, predicción, probabilidad, score, segmento, ranking, anomalía, recomendación o conjunto de indicadores.
- Tipo de dato y significado de la salida.
- Nivel de granularidad de la salida: por cliente, producto, operación, día, texto, municipio, etc.
- Formato previsto: tabla, fichero CSV/Parquet, vista SQL, dashboard, informe, API o aplicación.
- Cómo utilizará el usuario la salida y qué decisión podrá tomar.
- Qué explicación, intervalo, nivel de confianza o información adicional será necesario mostrar.

Campo de salida	Descripción	Tipo	Uso posterior
id_entidad	Identificador de la unidad analizada o predicha.	string / integer	Trazabilidad y unión con el resto del proyecto.
prediccion_o_score	Resultado principal del modelo o análisis.	float / categoría	Dashboard, ranking, alerta o recomendación.
fecha_ejecucion	Momento en que se genera el resultado.	datetime	Control de actualización y reproducibilidad.
explicacion	Motivo, factores principales o contexto del resultado.	texto	Interpretación por parte del usuario.

6. Estrategia para diseñar y seleccionar el modelo

Explicad el proceso que seguiréis para construir y comparar las alternativas. Debe quedar claro cómo evitaréis escoger un modelo únicamente porque produce una métrica aparentemente alta.

- Preparación del dataset de modelado a partir de la capa gold.
- Definición de la variable objetivo o, si no existe, de la salida que se quiere generar.
- Construcción de un baseline sencillo.
- Selección de pocos modelos candidatos y justificación de cada uno.
- Preprocesamiento necesario: tratamiento de nulos, escalado, codificación, selección o creación de variables.
- Criterios de comparación: calidad predictiva, estabilidad, interpretabilidad, coste computacional, complejidad y utilidad para el MVP.
- Regla de decisión final: qué condiciones deberá cumplir un modelo para ser seleccionado.

La selección del modelo no debe basarse solo en obtener la mejor métrica. Un modelo ligeramente menos preciso puede ser más adecuado si es más estable, explicable, reproducible y útil para el usuario final.

7. Estrategia de validación y evaluación

Definid cómo comprobaréis la calidad de los resultados y la capacidad del modelo para funcionar con datos no utilizados durante el entrenamiento. La validación debe reproducir, en la medida de lo posible, el uso real del sistema.

- Cómo separaréis los datos de entrenamiento, validación y prueba.

- Si utilizaréis una separación aleatoria, estratificada, temporal, por grupos o mediante backtesting, y por qué.
- Cómo evitaréis que la misma entidad o información futura aparezca simultáneamente en entrenamiento y prueba.
- Qué métricas utilizaréis y por qué son adecuadas para el problema.
- Cómo compararéis los resultados con el baseline.
- Cómo analizaréis los errores, los casos extremos y el rendimiento por segmentos o periodos.
- Qué resultado mínimo consideraríais aceptable y qué haríais si ningún modelo lo alcanza.

Elegid métricas coherentes con el tipo de tarea. Por ejemplo, MAE o RMSE en regresión; precision, recall, F1 o matriz de confusión en clasificación; error por horizonte y backtesting en forecasting; y métricas de ranking, cobertura o validación cualitativa en recomendadores.

Elemento	Decisión prevista	Justificación
Separación de datos	Train / validación / test, split temporal, por grupos...	Debe evitar contaminación y parecerse al uso real.
Métrica principal	MAE, recall, F1, RMSE, Precision@K...	Debe reflejar el coste o utilidad del error.
Baseline	Regla o modelo simple	Permite medir la mejora real.
Criterio de aceptación	Umbral o mejora mínima	Define cuándo el resultado es suficientemente útil.

8. Riesgos y alternativas

Cerrad el documento con una valoración breve de los principales riesgos del análisis y del modelado. Debéis responder de forma concreta:

- ¿La variable objetivo está disponible y representa realmente el fenómeno que queréis predecir?
- ¿Existe riesgo de data leakage o de utilizar información que no estaría disponible en el momento real de uso?
- ¿El volumen, el histórico y la calidad de los datos son suficientes para entrenar y validar?
- ¿Hay clases desbalanceadas, cambios temporales, sesgos de cobertura o segmentos con pocos datos?
- ¿Qué parte de la estrategia genera más incertidumbre?
- ¿Qué alternativa aplicaríais si el modelo no supera el baseline o no puede validarse con rigor?

Criterios de corrección

Criterio	Qué se valorará
Claridad del problema	Problema, usuario y decisión deben quedar definidos con precisión.
Coherencia del análisis	El análisis debe responder preguntas útiles y alimentar el MVP.
Adecuación de los modelos	Los modelos deben ser adecuados al problema, los datos y el alcance.
Entradas y salidas	Deben definirse los datos gold, la granularidad y la salida.
Baseline y selección	Debe existir un baseline y criterios explícitos de comparación.
Validación y métricas	La evaluación debe evitar leakage y medir la capacidad predictiva.
Riesgos y alternativas	Deben identificarse riesgos concretos y planes alternativos.
Realismo e integración	La estrategia debe ser viable y la salida integrable en el MVP.
Trazabilidad del trabajo	El repositorio debe conservar las cuatro entregas.

Resultado esperado

Al finalizar esta entrega, el repositorio debe permitir entender qué problema se quiere resolver y qué utilidad aportará el resultado; qué análisis se realizará; qué modelos o enfoques se compararán; cuáles serán los datos de entrada y salida; qué baseline, estrategia de validación y métricas se utilizarán; cómo se seleccionará e integrará el modelo más adecuado en el MVP; y qué riesgos y alternativas existen.